Bầy ong ra quyết định trên đồ thị: tái tạo và mở rộng HiveMindRL

Đồ án tổng hợp — Trí tuệ nhân tạo

Ngày 27 tháng 10 năm 2026

Tóm tắt

Bài báo *The hive mind is a single reinforcement learning agent* (Soma và cộng sự, 2026) chứng minh rằng một đàn cá thể chỉ bắt chước lẫn nhau vẫn tạo ra hành vi học tập tương đương một tác tử học tăng cường duy nhất, với điều kiện quần thể được trộn đều. Đồ án này gồm hai phần. Phần thứ nhất tái tạo kết quả cốt lõi của bài báo bằng NumPy: đường học của mô hình bầy đàn, của thuật toán Maynard-Cross Learning song song, và của nghiệm giải tích trùng nhau với sai lệch lớn nhất 0,018. Phần thứ hai đặt đàn lên một đồ thị giao tiếp cố định — đúng phần mà bài báo để ngỏ — và hỏi cấu trúc đồ thị thay đổi tốc độ học như thế nào. Khảo sát 19 cấu hình trên hai họ đồ thị cho thấy giả thuyết ban đầu (thời gian hội tụ tỉ lệ với thời gian relaxation $\tau = 1/(1-\lambda_2)$ của đồ thị) chỉ đúng trong từng họ. Một đại lượng đơn giản hơn — đường đi trung bình L — mô tả được cả hai họ bằng một quy luật tuyến tính: $t_{90} = 46{,}0 + 3{,}26 \cdot L$ với $R^2 = 0{,}93$. Kết quả này phù hợp với trực giác rằng bắt chước có trọng số là một quá trình có thiên lệch, lan truyền theo khoảng cách chứ không khuếch tán theo thời gian trộn.

1. Giới thiệu

Một đàn ong chọn tổ mới không có ai chỉ huy. Mỗi con khảo sát một địa điểm, đánh giá chất lượng, rồi truyền thông tin cho những con khác. Cuối cùng cả đàn thường đồng thuận về địa điểm tốt nhất. Hiện tượng này — trí tuệ bầy đàn — đặt một câu hỏi lý thuyết rõ ràng: hành vi học tập ở cấp tập thể có thể được mô tả bằng một thuật toán học tăng cường ở cấp cá nhân không?

Soma và cộng sự (2026) trả lời là có, trong giới hạn của mô hình. Họ chứng minh hai mệnh đề. Mệnh đề thứ nhất chỉ ra rằng quy tắc *bắt chước cá thể thành công* tương đương với Taylor Replicator Dynamics, và do đó tương đương với Cross Learning. Mệnh đề thứ hai chỉ ra rằng *weighted voter model* — nơi mỗi cá thể quảng bá lựa chọn của mình với cường độ tỉ lệ với phần thưởng nhận được — tương đương với một thuật toán mới do họ đề xuất, Maynard-Cross Learning (MCL). MCL khác Cross Learning ở chỗ chia tín hiệu phần thưởng cho giá trị kỳ vọng của chính sách hiện tại, nhờ đó tín hiệu được chuẩn hoá theo chất lượng chung của hệ thống.

Điểm yếu của chứng minh là giả định **trộn đều**: mỗi cá thể được coi là quan sát được toàn bộ quần thể, hoặc một vùng lân cận ngẫu nhiên đủ lớn. Chính bài báo thừa nhận điều này ở mục 4.9.2: "*The well-mixed assumption of Proposition 2 may not hold in the presence of spatial structure… We leave the investigation of spatial structure and heterogeneity in our framework for future work.*"

Đồ án này đi vào đúng khoảng trống đó. Câu hỏi nghiên cứu:

> Khi đàn được đặt lên một đồ thị giao tiếp cố định và mỗi cá thể chỉ quan sát hàng xóm của mình, cấu trúc đồ thị thay đổi tốc độ và độ chính xác của việc học như thế nào?

Đóng góp của đồ án gồm ba phần:

1. Một bản cài đặt độc lập, có kiểm thử, tái tạo được kết quả cốt lõi của bài báo (Hình 1).

2. Một khảo sát thực nghiệm trên 19 cấu hình đồ thị thuộc hai họ có tham số liên tục (Hình 2, 3; Bảng 1).
3. Một phát hiện: thời gian hội tụ tuân theo **đường đi trung bình** của đồ thị, không phải thời gian relaxation phổ, và một lý giải cho hiện tượng đó.

2. Cơ sở lý thuyết

2.1. Multi-armed bandit

Môi trường gồm n hành động. Mỗi hành động a có chất lượng ẩn q_a. Khi hành động được chọn, môi trường trả về phần thưởng nhiễu

$$r_a \sim U(q_a - \Delta, q_a + \Delta)$$

Trong đồ án, $n = 10$, $\Delta = 0{,}1$, và q_a cách đều trên đoạn $[0{,}4;\ 0{,}7]$ (kịch bản *middle* của bài báo). Phần thưởng luôn được kẹp vào $[0, 1]$ như bài báo yêu cầu.

2.2. Cross Learning và Maynard-Cross Learning

Với chính sách π và hành động k vừa chọn cùng phần thưởng r_k:

$$\text{Cross Learning:} \quad \pi'_a = \pi_a + \alpha \cdot r_k \cdot (1[a=k] - \pi_a)$$
$$\text{Maynard-Cross Learning:} \quad \pi'_a = \pi_a + \alpha \cdot (r_k / v_\pi) \cdot (1[a=k] - \pi_a)$$

trong đó $v_\pi = \Sigma_a \pi_a q_a$. Lấy kỳ vọng theo $k \sim \pi$ cho ra hai phương trình vi phân:

$$\text{TRD:} \quad \dot{\pi}_a = \pi_a(q_a - v_\pi)$$
$$\text{MRD:} \quad \dot{\pi}_a = \pi_a(q_a - v_\pi)/v_\pi$$

Bản song song của MCL — dùng B mẫu hành động/phần thưởng trong một bước — có một dạng rút gọn đáng chú ý. Với $\alpha = 1/B$:

$$\pi'_a = \Sigma_\{i:\ a_i = a\}\ r_i \ /\ \Sigma_i\ r_i$$

Tức là chính sách mới đúng bằng **tần suất hành động có trọng số phần thưởng**. Đây cũng chính là công thức cập nhật của weighted voter. Sự trùng khớp này là nội dung thực chất của Mệnh đề 2, và là lý do hai mô hình cho ra cùng đường học.

2.3. Weighted voter model

Mỗi cá thể i giữ một lựa chọn T_i, nhận phần thưởng r_i, và bắt chước một hàng xóm. Xác suất chọn phương án a tỉ lệ với tổng phần thưởng của những hàng xóm đang chọn a:

$$v^{(i)}_a = \Sigma_\{j \in N(i),\ T_j = a\}\ r_j \ /\ \Sigma_\{j \in N(i)\}\ r_j$$

Trong mô hình well-mixed, $N(i)$ là toàn bộ quần thể trừ chính i. Trong mô hình đồ thị, $N(i)$ là tập hàng xóm cố định của i.

2.4. Hai thước đo cấu trúc đồ thị

Thời gian relaxation. Gọi $S = D^{-1/2} A D^{-1/2}$ là ma trận kề chuẩn hoá của đồ thị, λ_2 là eigenvalue lớn thứ hai. Đại lượng

$$\tau = 1/(1 - \lambda_2)$$

là thang thời gian của quá trình khuếch tán trên đồ thị. $\tau \approx 1$ tương ứng quần thể trộn đều; τ lớn tương ứng thông tin lan chậm. Lưu ý λ_2 một mình không đủ: với chu trình 500 đỉnh, $\lambda_2 = 0{,}9996$ trông gần hoàn hảo nhưng $\tau \approx 2714$ bước.

Đường đi trung bình. L là khoảng cách ngắn nhất trung bình trên mọi cặp đỉnh liên thông. Đây là thang *khoảng cách* của đồ thị, không phải thang *thời gian trộn*.

3. Phương pháp

3.1. Cài đặt

Toàn bộ mô phỏng viết bằng Python với NumPy và SciPy, vector hoá theo từng bước quyết định, không dùng GPU. Mã nguồn gồm sáu mô-đun: môi trường bandit, các luật cập nhật chính sách, mô hình bầy đàn, sinh đồ thị và đại lượng phổ, đo lường, và hai kịch bản thí nghiệm. Mỗi mô-đun có kiểm thử đơn vị; các kiểm thử được viết trước phần cài đặt.

Một điểm kỹ thuật đáng nêu: bước cập nhật trên đồ thị được tính bằng một phép nhân thưa

```
W = A · (onehot(T) ⊙ r)
```

cho ra ma trận $N \times n$ trọng số phiếu của từng cá thể, sau đó lấy mẫu theo hàng. Nhờ vậy chi phí mỗi bước là $O(|E| \cdot n)$ thay vì $O(N^2)$, và toàn bộ khảo sát 19 cấu hình × 100 seed × 400 bước chạy trong khoảng 110 giây trên CPU thường.

3.2. Tham số

Thí nghiệm A (tái tạo). $N = 1000$ cá thể, $n = 10$ phương án, $T = 300$ bước, 100 seed, $B = N = 1000$ mẫu song song cho P-MCL. Mọi phương pháp xuất phát từ cùng một phân bố đều.

Thí nghiệm B (đồ thị). $N = 500$, $T = 400$ bước, 100 seed, cùng bandit. Hai họ đồ thị:

- **Watts–Strogatz** với bậc $k = 6$, quét $p \in \{0; 10^{-4}; 10^{-3}; 0{,}01; 0{,}05; 0{,}1; 0{,}2; 0{,}4; 0{,}7; 1\}$. $p = 0$ là vòng tròn thuần, $p = 1$ là đồ thị ngẫu nhiên.
- **Random geometric graph** trên hình vuông đơn vị, bán kính $\text{radius} = c \cdot \sqrt{(\log N / (\pi N))}$, quét $c \in \{1{,}0; 1{,}2; \ldots; 2{,}5\}$. Hai giá trị đầu nằm dưới ngưỡng liên thông.

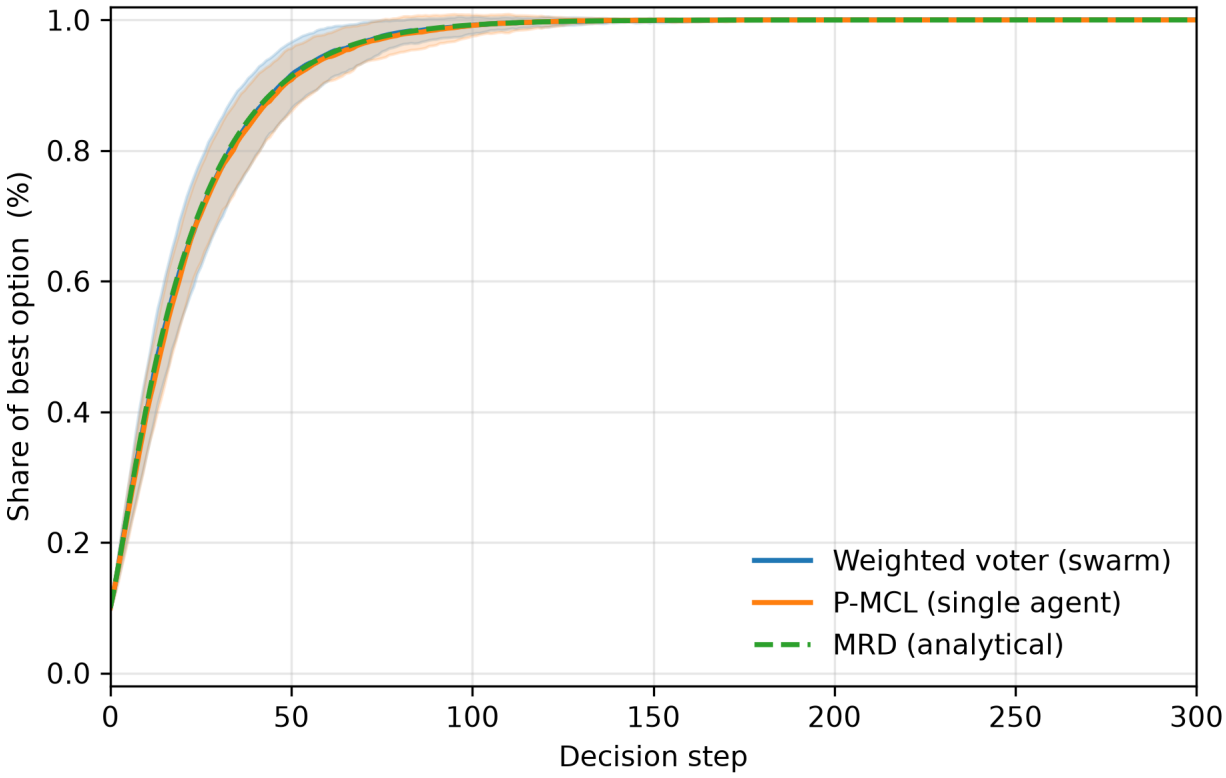
Mỗi cấu hình dùng **một đồ thị cố định** (seed 0) và 100 seed cho phần ngẫu nhiên của quá trình học. Cách này giữ τ và L cố định trong từng cấu hình, nhờ đó biến thiên quan sát được quy cho động lực học chứ không phải cho việc lấy mẫu đồ thị. Tham chiếu well-mixed dùng đồ thị đầy đủ ($\tau \approx 1$).

3.3. Đo lường

- t_{90}: bước đầu tiên mà trung bình trượt 5 bước của tỉ lệ cá thể chọn phương án tốt nhất đạt 0,9. Nếu không đạt trong T bước, giá trị được đánh dấu *censored* và báo cáo riêng thay vì gán bằng T.
- `final_best_mass`: trung bình tỉ lệ chọn phương án tốt nhất trong 10% bước cuối.
- `consensus`: khối lượng của phương án phổ biến nhất ở bước cuối.
- `l2_mrd`: khoảng cách RMS giữa đường học thực nghiệm và đường MRD.

4. Kết quả tái tạo

Hình 1 so sánh ba đường học trong 300 bước, trung bình trên 100 seed, dải tô là ±1 độ lệch chuẩn.



Hình 1. Đường học của bầy đàn, P-MCL và nghiệm giải tích MRD.

Ba đường gần như trùng nhau. Ở bước 50, tỉ lệ chọn phương án tốt nhất lần lượt là 0,916 (bầy đàn), 0,909 (P-MCL) và 0,914 (MRD). Sai lệch tuyệt đối lớn nhất giữa đường trung bình của P-MCL và MRD, tính từ bước 10 trở đi, là **0,018**.

Kết quả này tái tạo đúng kết luận của bài báo: khi số mẫu song song đủ lớn, cập nhật MCL bám sát nghiệm replicator dynamics, và mô hình bầy đàn cho ra cùng đường học. Đây là bằng chứng thực nghiệm cho Mệnh đề 2.

5. Kết quả trên đồ thị

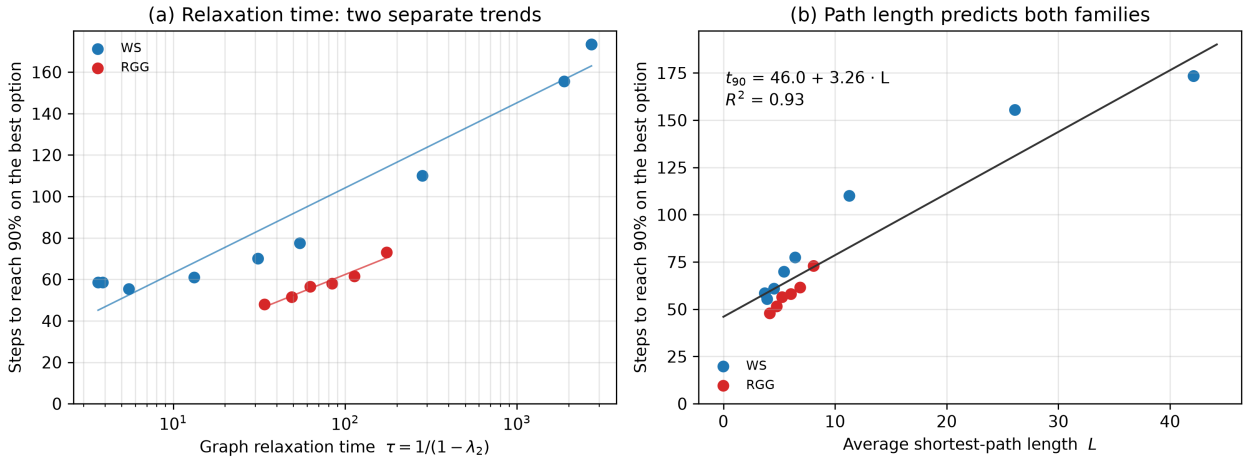
Bảng 1 tóm tắt 17 cấu hình liên thông. Hai cấu hình RGG dưới ngưỡng liên thông có $\tau = \infty$ nên không đưa vào bảng, nhưng vẫn được mô phỏng và báo cáo ở phần thảo luận.

Bảng 1. Kết quả khảo sát đồ thị (N = 500, 400 bước, 100 seed).

Họ	Tham số	τ	L	t_{90}	Tỉ lệ seed đạt	final
đầy đủ	—	1,0	1,0	44,0	1,00	1,00
RGG	c = 2,5	34,0	4,16	48,0	1,00	1,00
RGG	c = 2,0	62,6	5,26	56,5	1,00	1,00
RGG	c = 1,6	112,8	6,85	61,5	1,00	1,00
RGG	c = 1,4	173,9	8,08	73,0	1,00	1,00
WS	p = 1,0	3,65	3,69	58,5	1,00	1,00
WS	p = 0,4	5,50	3,92	55,5	1,00	1,00
WS	p = 0,1	31,1	5,40	70,0	1,00	1,00
WS	p = 0,05	54,4	6,43	77,5	1,00	1,00

Họ	Tham số	τ	L	t_{90}	Tỉ lệ seed đạt	final
WS	p = 0,01	281,2	11,26	110,0	1,00	1,00
WS	p = 10^{-3}	1878	26,09	155,5	0,96	1,00
WS	p = 0	2714	42,08	173,5	0,90	1,00

Hình 2 đặt hai thước đo cạnh nhau.



Hình 2. (a) Thời gian hội tụ theo thời gian relaxation. (b) Thời gian hội tụ theo đường đi trung bình.

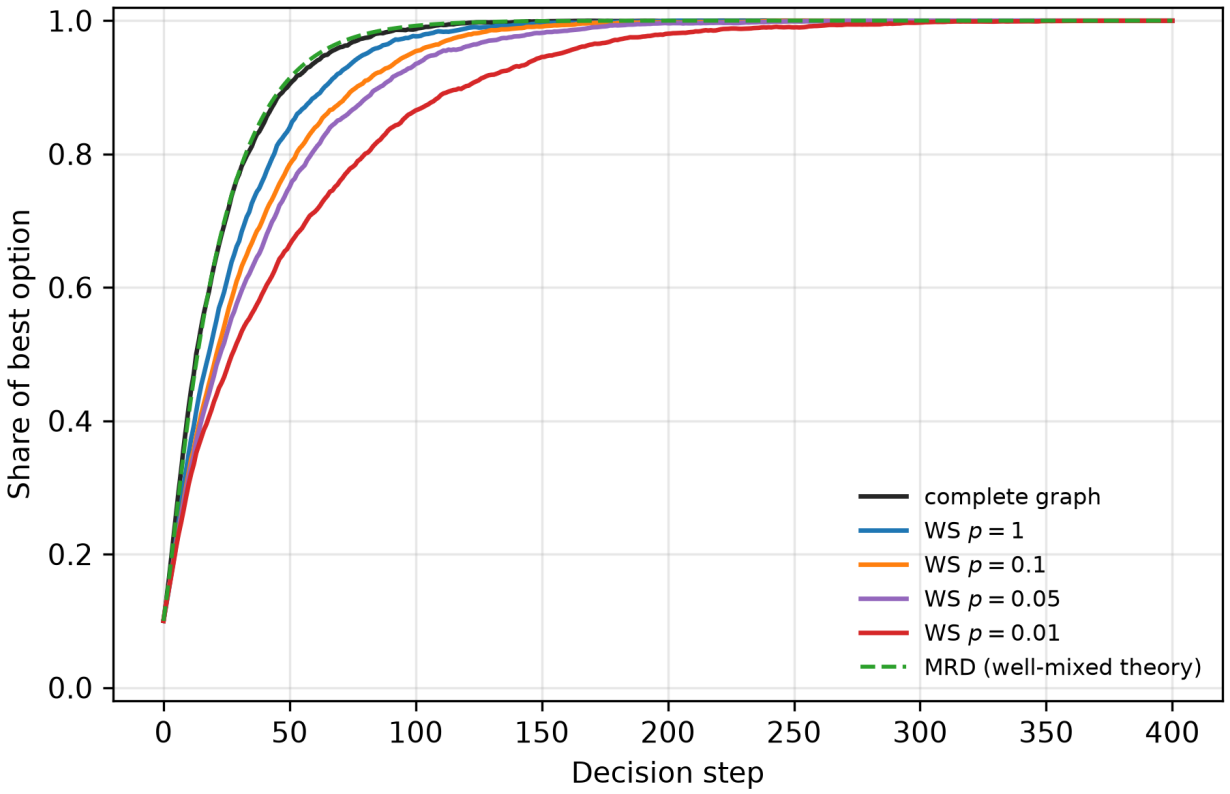
Giả thuyết ban đầu không đứng vững ở dạng phổ quát. Ở đồ thị (a), mỗi họ có xu hướng tăng đơn điệu theo τ, nhưng hai họ nằm ở hai đường khác nhau: tại cùng $\tau \approx 100$, RGG cần khoảng 62 bước còn WS cần khoảng 100 bước. Hệ số tương quan hạng Spearman giữa t_{90} và τ là 0,74.

Đường đi trung bình mô tả được cả hai họ. Ở đồ thị (b), các điểm của cả WS lẫn RGG nằm quanh một đường thẳng:

$$t_{90} = 46{,}0 + 3{,}26 \cdot L, \qquad R^2 = 0{,}93$$

Hệ số tương quan hạng với L là 0,85. Đáng chú ý là tung độ gốc 46,0 xấp xỉ $t_{90} = 44{,}0$ đo được trên đồ thị đầy đủ — nghĩa là có thể đọc quy luật này như **thời gian học nội tại của đàn cộng với thời gian thông tin đi hết đồ thị**.

Hình 3 cho thấy hình dạng đường học thay đổi thế nào khi nới dần vòng tròn.



Hình 3. Đường học trung bình trên một số cấu hình tiêu biểu.

Đồ thị đầy đủ và MRD gần như trùng nhau. Khi p giảm, đường học kéo dài về phía phải nhưng vẫn tiến tới 1. Với vòng tròn thuần (`p = 0`), đàn vẫn đạt 100% sau 400 bước, chỉ chậm hơn khoảng bốn lần so với đồ thị đầy đủ.

Một quan sát phụ: ở hầu hết cấu hình, `final_best_mass = 1,00` và `consensus = 1,00`. Ngay cả hai đồ thị RGG bị phân mảnh cũng đạt 0,96–1,00. Nói cách khác, **cấu trúc đồ thị ảnh hưởng mạnh tới tốc độ nhưng hầu như không ảnh hưởng tới độ chính xác** trong dải tham số đã khảo sát, vì mỗi thành phần liên thông vẫn đủ lớn để tự học đúng.

6. Thảo luận

Vì sao đường đi trung bình lại dự báo tốt hơn thời gian relaxation?

Spectral gap đo mode chậm nhất của một quá trình **khuếch tán** — một hạt ngẫu nhiên đi lang thang cho tới khi mất tương quan. Nhưng bắt chước có trọng số không phải quá trình khuếch tán thuần: phương án có phần thưởng cao được sao chép với xác suất cao hơn, tạo ra một **dòng trôi có hướng**. Dưới tác dụng của dòng trôi, kiểu tốt nhất lan ra như một mặt trận chuyển động với vận tốc xấp xỉ không đổi, nên thời gian để nó phủ 90% quần thể bị chi phối bởi **khoảng cách phải đi**, tức L, chứ không phải bởi thời gian trộn của bước đi ngẫu nhiên.

Cách giải thích này khớp với ba quan sát. Thứ nhất, tung độ gốc của quy luật xấp xỉ thời gian học của quần thể trộn đều — phần "không phụ thuộc đồ thị" đúng là động lực học chọn lọc thuần tuý. Thứ hai, hai họ đồ thị có cùng L nhưng khác số chiều (vòng 1D so với mặt phẳng 2D) lại nằm sát nhau hơn nhiều so với khi so theo τ. Thứ ba, đường học trên vòng tròn có dạng kéo dài chứ không phải trễ rồi bùng nổ — dấu hiệu của lan truyền theo khoảng cách.

Cần nói rõ giới hạn của kết luận này. τ và L tương quan chặt với nhau (cùng giảm khi tăng rewiring), nên phép so sánh trên **chưa tách được hai biến**. Một kiểm định sạch sẽ cần các đồ thị được ghép sao cho L bằng nhau nhưng τ khác nhau — ví dụ đồ thị hai buồng nối bằng một cầu hẹp. Đó là việc của bước tiếp theo, không phải kết luận của đồ án này.

7. Hạn chế

1. **Censoring.** Hai cấu hình chậm nhất có 4–10% seed không đạt 0,9 trong 400 bước, nên t_{90} trung vị bị lệch xuống. Đã báo cáo riêng tỉ lệ đạt thay vì che đi.
2. **Cùng một kịch bản chất lượng.** Thí nghiệm đồ thị chỉ dùng $q \in [0{,}4;\ 0{,}7]$. Với dải chất lượng thấp hơn, nhiễu tương đối lớn hơn và đàn dễ kẹt ở phương án tầm trung.
3. **Chỉ hai họ đồ thị, bậc tương đối đồng nhất.** Chưa khảo sát mạng có phân bố bậc nặng đuôi; trên các mạng đó, weighted voter có thiên lệch theo bậc và kết luận có thể khác.
4. **Không có cơ chế khám phá.** Như bài báo gốc, khi một phương án biến mất khỏi quần thể thì nó không thể quay lại. Trong môi trường thay đổi theo thời gian, đàn sẽ không thích nghi được.
5. t_{90} **phụ thuộc ngưỡng và cửa sổ làm trơn.** Đã cố định 0,9 và 5 bước cho mọi cấu hình, nhưng các ngưỡng khác có thể cho hệ số hồi quy khác.

8. Kết luận

Đồ án tái tạo thành công kết quả cốt lõi của Soma và cộng sự: một đàn cá thể chỉ bắt chước lẫn nhau cho ra đường học trùng với một tác tử học tăng cường duy nhất, sai lệch dưới 0,02.

Khi phá vỡ giả định trộn đều bằng cách đặt đàn lên đồ thị, kết quả cho thấy tốc độ học bị chi phối bởi **khoảng cách thông tin**, không phải thời gian trộn phổ. Cụ thể, $t_{90} = 46{,}0 + 3{,}26 \cdot L$ với $R^2 = 0{,}93$ trên cả hai họ đồ thị. Độ chính xác cuối cùng gần như không đổi trong dải khảo sát.

Về mặt phương pháp, đồ án cho thấy một hướng nghiên cứu nhỏ nhưng trọn vẹn: lấy một chứng minh có điều kiện, phá điều kiện đó, đo cái gì thay đổi, và tìm đại lượng thay thế mô tả được hiện tượng. Bước tiếp theo rõ ràng nhất là tách L khỏi τ bằng các đồ thị ghép có cùng đường đi trung bình nhưng khác spectral gap.

Tài liệu tham khảo

1. Soma, K., Bouteiller, Y., Hamann, H., Beltrame, G. (2026). The hive mind is a single reinforcement learning agent. *Swarm Intelligence*, 20. https://doi.org/10.1007/s11721-026-00264-7
2. Nowak, M. A. (2006). *Evolutionary Dynamics: Exploring the Equations of Life*. Harvard University Press.
3. Ohtsuki, H., Hauert, C., Lieberman, E., Nowak, M. A. (2006). A simple rule for the evolution of cooperation on graphs and social networks. *Nature*, 441, 502–505.
4. Watts, D. J., Strogatz, S. H. (1998). Collective dynamics of small-world networks. *Nature*, 393, 440–442.
5. Penrose, M. (2003). *Random Geometric Graphs*. Oxford University Press.
6. Sutton, R. S., Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.